Learning as Geometry

Nota tecnica — Schema per futura collaborazione

Blocco 1: La varietà parametrica $\mathcal{M}$ e la metrica di Fisher

Riccardo Del Gratta

CNR-IBF Pisa

Aprile 2026 — bozza di lavoro

Descrizione degli ambienti

Questa è una nota di lavoro una futura collaborazione.

L'obiettivo è presentare la struttura concettuale — non le dimostrazioni. Ogni passo è classificato esplicitamente:

- **verde** = derivato/difendibile,
- **blu** = assunzione in uso,
- **viola** = congettura aperta,
- **ambra** = limite/approssimazione.

Nota

Questo esempio precede il Blocco 1 formale. L'obiettivo è vedere esplicitamente perché $\Theta \subseteq \mathbb{R}^4$ (spazio piatto) e $\mathcal{M} = (\Theta, g)$ (spazio curvo) sono oggetti diversi, e come la curvatura di $\mathcal{M}$ emerga interamente da p_θ. Ogni derivata è scritta per esteso — nessun salto.

1 Setup: il modello più semplice non banale

1.1 Architettura

Un layer lineare $\mathbb{R}^2 \to \mathbb{R}^2$ senza bias, seguito da softmax:

$$f_\theta(x) = Wx, \qquad W = \begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{pmatrix} \in \mathbb{R}^{2\times 2}. \tag{1}$$

I parametri sono $\theta = (w_{11}, w_{12}, w_{21}, w_{22}) \in \mathbb{R}^4$. Lo spazio dei parametri è $\Theta \subseteq \mathbb{R}^4$ — euclideo, piatto.

L'input è $x = (x_1, x_2)^\top \in \mathbb{R}^2$, l'output è una distribuzione su $K = 2$ classi.

1.2 Logits e softmax

I logits (pre-softmax) sono:

$$z = Wx = \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} = \begin{pmatrix} w_{11}x_1 + w_{12}x_2 \\ w_{21}x_1 + w_{22}x_2 \end{pmatrix}. \tag{2}$$

La softmax produce la distribuzione condizionata:

$$p_\theta(y = k|x) = \frac{e^{z_k}}{e^{z_1} + e^{z_2}} =: \sigma_k(z), \qquad k \in \{1, 2\}. \tag{3}$$

Notazione compatta: $p_k \equiv \sigma_k(z)$, con $p_1 + p_2 = 1$.

Perche' softmax + NLL

La Fisher identity $g_{ij} = \mathbb{E}[H_{ij}]$ è esatta solo per NLL. La softmax garantisce che $p_\theta(y|x)$ sia una distribuzione di probabilità ben definita per ogni θ — condizione necessaria per definire la Fisher.

CONFIDENTIAL

2 Log-likelihood e NLL

Per un singolo campione (x, y) con $y \in \{1, 2\}$, la log-likelihood è:

$$\log p_\theta(y|x) = \log \sigma_y(z) = z_y - \log(e^{z_1} + e^{z_2}). \tag{4}$$

La NLL per campione è $\ell(\theta; x, y) = -\log p_\theta(y|x)$.

Esplicitando per classe:

$$y = 1: \quad \log p_\theta = w_{11}x_1 + w_{12}x_2 - \log\big(e^{w_{11}x_1 + w_{12}x_2} + e^{w_{21}x_1 + w_{22}x_2}\big), \tag{5}$$

$$y = 2: \quad \log p_\theta = w_{21}x_1 + w_{22}x_2 - \log\big(e^{w_{11}x_1 + w_{12}x_2} + e^{w_{21}x_1 + w_{22}x_2}\big). \tag{6}$$

3 Gradienti della log-likelihood

Indicizziamo i parametri come $\theta^1 = w_{11}$, $\theta^2 = w_{12}$, $\theta^3 = w_{21}$, $\theta^4 = w_{22}$.

Sia $S(z) = e^{z_1} + e^{z_2}$ la funzione di partizione. Allora $\partial_k \log S = p_k \cdot \partial_k z_k / \partial_k z_k$ — calcoliamo esplicitamente.

3.1 Derivate dei logits rispetto ai parametri

Dalla definizione (2):

$$\frac{\partial z_1}{\partial w_{11}} = x_1, \quad \frac{\partial z_1}{\partial w_{12}} = x_2, \quad \frac{\partial z_1}{\partial w_{21}} = 0, \quad \frac{\partial z_1}{\partial w_{22}} = 0, \tag{7}$$

$$\frac{\partial z_2}{\partial w_{11}} = 0, \quad \frac{\partial z_2}{\partial w_{12}} = 0, \quad \frac{\partial z_2}{\partial w_{21}} = x_1, \quad \frac{\partial z_2}{\partial w_{22}} = x_2. \tag{8}$$

3.2 Derivate della log-likelihood

Da (4): $\log p_\theta(y|x) = z_y - \log S$.

Gradiente della log-likelihood — forma generale

Per ogni parametro θ^i:

$$\frac{\partial \log p_\theta(y|x)}{\partial \theta^i} = \frac{\partial z_y}{\partial \theta^i} - \sum_{k=1}^{2} p_k \frac{\partial z_k}{\partial \theta^i}. \tag{9}$$

Il primo termine seleziona la classe vera y; il secondo sottrae la media pesata sui logits — è l'aspettativa del gradiente sotto il modello.

Applicando (9) a ciascun parametro, caso $y = 1$ (il caso $y = 2$ è simmetrico):

$$\frac{\partial \log p_\theta}{\partial w_{11}} = x_1 - p_1 x_1 = (1 - p_1)\, x_1 = p_2\, x_1, \tag{10}$$

$$\frac{\partial \log p_\theta}{\partial w_{12}} = x_2 - p_1 x_2 = p_2\, x_2, \tag{11}$$

$$\frac{\partial \log p_\theta}{\partial w_{21}} = 0 - p_2 x_1 = -p_2\, x_1, \tag{12}$$

$$\frac{\partial \log p_\theta}{\partial w_{22}} = 0 - p_2 x_2 = -p_2\, x_2. \tag{13}$$

In forma vettoriale (per $y = 1$), il gradiente rispetto a $\theta \in \mathbb{R}^4$ è:

$$\nabla_\theta \log p_\theta(y{=}1|x) = p_2 \cdot \begin{pmatrix} x_1 \\ x_2 \\ -x_1 \\ -x_2 \end{pmatrix}. \tag{14}$$

CONFIDENTIAL

Nota

Il gradiente dipende da θ attraverso $p_2 = p_2(\theta, x)$. In punti diversi di Θ il gradiente cambia — questo è ciò che rende la Fisher non costante su Θ.

4 La matrice di Fisher esplicita

La Fisher è il valore atteso del prodotto esterno del gradiente:

$$g_{ij}(\theta) = \mathbb{E}_{(x,y)\sim p_\theta}\left[\frac{\partial \log p_\theta(y|x)}{\partial \theta^i} \cdot \frac{\partial \log p_\theta(y|x)}{\partial \theta^j}\right]. \tag{15}$$

4.1 Struttura a blocchi del gradiente

Prima di calcolare il prodotto esterno, osserviamo la struttura del gradiente (14). Per $y = 1$ il vettore in $\mathbb{R}^4$ ha la forma:

$$\nabla_\theta \log p_\theta(y{=}1|x) = p_2 \underbrace{\begin{pmatrix} x_1 \\ x_2 \\ -x_1 \\ -x_2 \end{pmatrix}}_{=:\,v} = p_2 \begin{pmatrix} x \\ -x \end{pmatrix}, \qquad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2. \tag{16}$$

Il vettore $v = (x^\top, -x^\top)^\top$ ha una struttura a due blocchi: il primo blocco corrisponde alle righe di W che determinano z_1, il secondo a quelle che determinano z_2, con segno opposto.

Per $y = 2$ il calcolo esplicito (simmetrico a $y = 1$, scambiando $p_1 \leftrightarrow p_2$) dà:

$$\frac{\partial \log p_\theta(y{=}2|x)}{\partial w_{11}} = 0 - p_1 x_1 = -p_1 x_1, \tag{17}$$

$$\frac{\partial \log p_\theta(y{=}2|x)}{\partial w_{12}} = 0 - p_1 x_2 = -p_1 x_2, \tag{18}$$

$$\frac{\partial \log p_\theta(y{=}2|x)}{\partial w_{21}} = x_1 - p_2 x_1 = p_1 x_1, \tag{19}$$

$$\frac{\partial \log p_\theta(y{=}2|x)}{\partial w_{22}} = x_2 - p_2 x_2 = p_1 x_2, \tag{20}$$

ovvero:

$$\nabla_\theta \log p_\theta(y{=}2|x) = p_1 \begin{pmatrix} -x \\ x \end{pmatrix} = -p_1 \begin{pmatrix} x \\ -x \end{pmatrix} = -p_1\, v. \tag{21}$$

Notare: per $y = 2$ il gradiente è $-p_1 v$, non $p_1 v$ — il segno cambia perché la classe selezionata è diversa.

CONFIDENTIAL

4.2 Prodotto esterno del gradiente

Il prodotto esterno $v \otimes v = vv^\top$ con $v = (x_1, x_2, -x_1, -x_2)^\top$ è:

$$vv^\top = \begin{pmatrix} x \\ -x \end{pmatrix} \begin{pmatrix} x^\top & -x^\top \end{pmatrix} = \begin{pmatrix} xx^\top & -xx^\top \\ -xx^\top & xx^\top \end{pmatrix}. \tag{22}$$

Questa matrice 4×4 ha una struttura a blocchi 2×2, con blocchi $\pm xx^\top \in \mathbb{R}^{2\times 2}$. In forma compatta, usando il prodotto di Kronecker:

$$vv^\top = xx^\top \otimes \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}. \tag{23}$$

La matrice $\begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ è la **struttura di segno** del layer softmax a 2 classi: codifica il fatto che il gradiente rispetto al blocco della classe giusta ha segno $+$, quello della classe sbagliata ha segno $-$.

Esplicitando le equazioni (16) e (21):

$$\nabla \log p_\theta \otimes \nabla \log p_\theta\big|_{y=1} = (p_2 v)(p_2 v)^\top = p_2^2\, vv^\top, \tag{24}$$

$$\nabla \log p_\theta \otimes \nabla \log p_\theta\big|_{y=2} = (-p_1 v)(-p_1 v)^\top = p_1^2\, vv^\top. \tag{25}$$

I due prodotti esterni hanno la **stessa** struttura $vv^\top$ — differiscono solo per il coefficiente scalare p_2^2 vs p_1^2.

4.3 Aspettativa su y

L'aspettativa rispetto a $y \sim p_\theta(\cdot|x)$ è la media pesata sui valori possibili di y, con pesi p_1 e p_2:

$$\begin{aligned}\mathbb{E}_y[\nabla \log p_\theta \otimes \nabla \log p_\theta] &= \sum_{k=1}^{2} p_\theta(y{=}k|x) \cdot \Big(\nabla \log p_\theta \otimes \nabla \log p_\theta\big|_{y=k}\Big) \\ &= p_1 \cdot (p_2^2\, vv^\top) + p_2 \cdot (p_1^2\, vv^\top) \\ &= \big(p_1 p_2^2 + p_2 p_1^2\big)\, vv^\top. \end{aligned} \tag{26}$$

$$\mathbb{E}_y[\nabla \log p_\theta \otimes \nabla \log p_\theta] = p_1 \cdot \big(p_2^2\, vv^\top\big) + p_2 \cdot \big(p_1^2\, vv^\top\big) \tag{27}$$

$$= \big(p_1 p_2^2 + p_2 p_1^2\big)\, vv^\top \tag{28}$$

$$= p_1 p_2 \underbrace{(p_1 + p_2)}_{=1}\, vv^\top \tag{29}$$

$$= p_1 p_2\, vv^\top \tag{30}$$

Raccogliendo $p_1 p_2$:

$$p_1 p_2^2 + p_2 p_1^2 = p_1 p_2 (p_2 + p_1) = p_1 p_2 \cdot 1 = p_1 p_2, \tag{31}$$

dove si è usato $p_1 + p_2 = 1$. Quindi:

$$\mathbb{E}_y[\nabla \log p_\theta \otimes \nabla \log p_\theta] = p_1 p_2\, vv^\top. \tag{32}$$

Sostituendo $vv^\top$ dalla (22):

$$\mathbb{E}_y[\nabla \log p_\theta \otimes \nabla \log p_\theta] = p_1 p_2 \begin{pmatrix} x_1^2 & x_1 x_2 & -x_1^2 & -x_1 x_2 \\ x_1 x_2 & x_2^2 & -x_1 x_2 & -x_2^2 \\ -x_1^2 & -x_1 x_2 & x_1^2 & x_1 x_2 \\ -x_1 x_2 & -x_2^2 & x_1 x_2 & x_2^2 \end{pmatrix}. \tag{33}$$

Poiché $p_1 + p_2 = 1$:

CONFIDENTIAL

Fisher per input fisso x

$$g_{ij}(\theta)\big|_x = p_1(\theta,x)\,p_2(\theta,x)\begin{pmatrix} x_1^2 & x_1x_2 & -x_1^2 & -x_1x_2 \\ x_1x_2 & x_2^2 & -x_1x_2 & -x_2^2 \\ -x_1^2 & -x_1x_2 & x_1^2 & x_1x_2 \\ -x_1x_2 & -x_2^2 & x_1x_2 & x_2^2 \end{pmatrix}. \tag{34}$$

La Fisher completa si ottiene mediando su $x \sim p_{\text{data}}$:

$$g_{ij}(\theta) = \mathbb{E}_x\left[p_1(\theta,x)\,p_2(\theta,x)\cdot xx^\top \otimes \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}\right]. \tag{35}$$

5 Lettura geometrica

Perche' $\mathcal{M} \neq \Theta$

La matrice (34) mostra tre cose esplicitamente:

1. $g_{ij}(\theta) \neq \delta_{ij}$: la metrica di Fisher non è la metrica euclidea di $\mathbb{R}^4$. $\mathcal{M} = (\Theta, g)$ non è piatto.

2. $g_{ij}(\theta)$ **dipende da** θ: il fattore $p_1(\theta,x)\,p_2(\theta,x)$ cambia in ogni punto di Θ. Vicino alla frontiera decisionale ($p_1 \approx p_2 \approx 0.5$) la metrica è massima: la geometria è "densa". Lontano dalla frontiera ($p_1 \approx 1$ o $p_2 \approx 1$) la metrica è quasi nulla: la geometria è quasi piatta.

3. $g_{ij}(\theta)$ **dipende da** x: la geometria di $\mathcal{M}$ cambia al variare della distribuzione dei dati. I dati *plasmano* la geometria dello spazio parametrico.

Singolarita' della Fisher

La matrice (34) ha rango 1 per ogni x fisso (è un prodotto esterno scalato). Solo dopo l'aspettativa su x — se la distribuzione dei dati copre direzioni diverse in $\mathbb{R}^2$ — la Fisher diventa non singolare.
Se i dati sono collineari ($x_2 = cx_1$ per ogni campione), la Fisher rimane singolare per ogni θ: $\mathcal{M}$ è uno spazio stratificato, non una varietà liscia.

Collegamento con il Blocco 1 formale

In questo esempio:

- $\Theta \subseteq \mathbb{R}^4$: struttura differenziabile (piatta, euclidea)
- $p_\theta(y|x)$: il modello statistico che genera la metrica
- $g_{ij}(\theta)$: campo Riemanniano su Θ, dipende da θ attraverso p_1p_2
- $\mathcal{M} = (\Theta, g)$: stessa topologia di $\mathbb{R}^4$, geometria curva indotta da p_θ

Il Blocco 1 formalizza questa struttura per un modello generale.

Nota

Questa sezione costruisce esplicitamente la catena di spazi e mappe per il modello 2×2 dell'esempio motivante. L'obiettivo è rendere precisa la distinzione tra Θ (struttura differenziabile, piatta) e $\mathcal{M}$ (struttura Riemanniana, curva).

6 La catena di spazi

Fissato un input $x \in \mathbb{R}^2$, la catena è:

$$\begin{tikzcd}
\boxed{\begin{array}{c}\Theta \subseteq \mathbb{R}^4 \\ \text{spazio parametri}\end{array}} \arrow[r, "\Phi_x"] \arrow[d, dashed, "\mathrm{id}_{\mathrm{diff}}\text{-pull-back}"'] & \boxed{\begin{array}{c}\mathcal{P}_x \cong (0,1) \\ \text{simplesso aperto}\end{array}} \arrow[dl, "\Phi_x^* g^{\mathcal{P}}"] \\
\boxed{\begin{array}{c}\mathcal{M} = (\Theta, g) \\ \text{varietà Riemanniana}\end{array}} &
\end{tikzcd}$$

La freccia tratteggiata $\mathrm{id}_{\mathrm{diff}}$ indica che $\mathcal{M}$ e Θ condividono la struttura differenziabile (sono diffeomorfi), ma *non* sono isometrici come varietà Riemanniane.

CONFIDENTIAL

7 Spazio 1: $\Theta \subseteq \mathbb{R}^4$

Definizione 7.1 (Spazio dei parametri)**.** Lo *spazio dei parametri* è

$$\Theta = \mathbb{R}^4 \ni \theta = (w_{11}, w_{12}, w_{21}, w_{22}). \tag{36}$$

Θ è una varietà differenziabile con l'atlante globale $\{(\Theta, \mathrm{id})\}$ e metrica euclidea

$$\delta = \delta_{ij}\, d\theta^i \otimes d\theta^j, \qquad \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j. \end{cases} \tag{37}$$

Come varietà Riemanniana (Θ, δ) è **piatta**: curvatura di Riemann nulla ovunque.

Cosa fornisce Θ

Θ fornisce la **struttura differenziabile**: le coordinate θ^i, gli spazi tangenti $T_\theta\Theta \cong \mathbb{R}^4$, la nozione di mappa liscia. Non fornisce la geometria rilevante per il training — quella viene da p_θ.

8 Spazio 2: $\mathcal{P}_x$ per x fisso

Fissato $x \in \mathbb{R}^2$, il modello produce una distribuzione su $K = 2$ classi: $p_\theta(\cdot|x) = (p_1, p_2)$ con $p_1 + p_2 = 1$ e $p_k > 0$.

Definizione 8.1 (Simplesso statistico aperto)**.** Lo *spazio delle distribuzioni* per x fisso è il simplesso aperto $(K-1)$-dimensionale:

$$\mathcal{P}_x = \Delta^{K-1}_{\text{open}} = \left\{ (p_1, \ldots, p_K) \in \mathbb{R}^K : \sum_{k=1}^{K} p_k = 1,\ p_k > 0 \right\}. \tag{38}$$

Per $K = 2$:

$$\mathcal{P}_x = \{(p_1, p_2) : p_1 + p_2 = 1,\ p_1, p_2 > 0\} \cong (0, 1), \tag{39}$$

via l'identificazione $(p_1, p_2) \leftrightarrow p_1 \in (0, 1)$. $\mathcal{P}_x$ è una varietà differenziabile di dimensione 1.

Perche' simplesso aperto e non chiuso

Si escludono $p_k = 0$: una distribuzione con probabilità nulla su una classe ha log-likelihood $-\infty$. La Fisher non è definita sul bordo del simplesso. Il simplesso aperto è la varietà naturale per la statistica.

Metrica di Fisher su $\mathcal{P}_x$

Su $\mathcal{P}_x \cong (0, 1)$, con coordinata $p = p_1$ (e $p_2 = 1 - p$), la metrica di Fisher è la metrica di informazione di Fisher scalare:

$$g_x^{\mathcal{P}}(p) = \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)} = \frac{1}{p_1 p_2}. \tag{40}$$

EDITIAL

Derivazione di $g_x^{\mathcal{P}}$

Per una distribuzione categorica $(p, 1-p)$ su $\{1, 2\}$, la log-likelihood di un singolo campione y è:

$$\ell(p; y) = y \log p + (1 - y) \log(1 - p), \quad y \in \{0, 1\}. \tag{41}$$

La derivata rispetto a p è:

$$\frac{\partial \ell}{\partial p} = \frac{y}{p} - \frac{1-y}{1-p} = \frac{y-p}{p(1-p)}. \tag{42}$$

La Fisher scalare su $\mathcal{P}_x$:

$$g_x^{\mathcal{P}} = \mathbb{E}_y \left[\left(\frac{\partial \ell}{\partial p} \right)^2 \right] = \mathbb{E}_y \left[\frac{(y-p)^2}{p^2(1-p)^2} \right]. \tag{43}$$

Poiché $y \in \{0, 1\}$ con $\mathbb{P}(y = 1) = p$:

$$\mathbb{E}_y[(y-p)^2] = p(1-p)^2 + (1-p)p^2 = p(1-p)\big[(1-p) + p\big] = p(1-p). \tag{44}$$

Quindi:

$$g_x^{\mathcal{P}} = \frac{p(1-p)}{p^2(1-p)^2} = \frac{1}{p(1-p)} = \frac{1}{p_1 p_2}. \tag{45}$$

Geometria di $\mathcal{P}_x$

La metrica $g_x^{\mathcal{P}} = 1/(p_1 p_2)$ diverge ai bordi $p_1 \to 0$ o $p_2 \to 0$ (classificazione perfetta) e raggiunge il minimo 4 a $p_1 = p_2 = 1/2$ (massima incertezza). Vicino al bordo il simplesso è "infinitamente grande" — piccole variazioni di θ che spostano p_1 vicino a 0 corrispondono a grandi distanze su $\mathcal{P}_x$.

9 La mappa parametrica Φ_x

Definizione 9.1 (Mappa parametrica per x fisso)**.** La *mappa parametrica* per input x fisso è:

$$\Phi_x : \Theta \to \mathcal{P}_x, \qquad \Phi_x(\theta) = p_\theta(\cdot|x) = (p_1(\theta, x),\, p_2(\theta, x)), \tag{46}$$

dove esplicitamente, con $z = Wx$:

$$p_1(\theta, x) = \frac{e^{w_{11}x_1 + w_{12}x_2}}{e^{w_{11}x_1 + w_{12}x_2} + e^{w_{21}x_1 + w_{22}x_2}}, \qquad p_2 = 1 - p_1. \tag{47}$$

Proprieta' di Φ_x

1. **Liscia**: $\Phi_x \in C^\infty(\Theta, \mathcal{P}_x)$ — la softmax è infinitamente differenziabile.
2. **Surgettiva**: $\Phi_x(\Theta) = \mathcal{P}_x$ — per ogni $(p_1, p_2) \in (0, 1)$ esiste θ tale che $p_\theta(\cdot|x) = (p_1, p_2)$.
3. **Non iniettiva**: se θ e θ' differiscono per una costante aggiunta a tutte le righe di W, producono la stessa softmax. Φ_x ha nucleo non banale — **non** è un'immersione.
4. **Differenziale**: per la coordinata $p_1 \in (0, 1)$,

$$D\Phi_x(\theta) = \nabla_\theta p_1(\theta, x) = p_1 p_2 \begin{pmatrix} x_1 \\ x_2 \\ -x_1 \\ -x_2 \end{pmatrix}^\top \in \mathbb{R}^{1\times 4}. \tag{48}$$

   Il differenziale è una mappa $\mathbb{R}^4 \to \mathbb{R}^1$ — ha rango al più 1. Φ_x **non** è un'immersione (dimensioni incompatibili: $\dim \Theta = 4 > \dim \mathcal{P}_x = 1$).

Φ_x non e' un'immersione

Una immersione richiede dim dominio $\leq$ dim codominio e differenziale iniettivo. Qui $\dim \Theta = 4 > \dim \mathcal{P}_x = 1$: Φ_x non può essere iniettiva sul differenziale. La mappa Φ_x è una **sommersione locale** (differenziale surgettivo) — l'opposto di una immersione. Questo riflette la sovraparametrizzazione: Θ ha molte più dimensioni di $\mathcal{P}_x$. La metrica di Fisher non viene da un pull-back di immersione — viene da un pull-back di sommersione.

10 Il pull-back della metrica

Definizione 10.1 (Pull-back della metrica di Fisher)**.** Il *pull-back* della metrica $g_x^{\mathcal{P}}$ tramite Φ_x è il campo tensoriale su Θ definito da:

$$(\Phi_x^* \, g_x^{\mathcal{P}})_\theta(u, v) = g_x^{\mathcal{P}}\big(\Phi_x(\theta)\big) \cdot \big\langle D\Phi_x(\theta)\, u,\ D\Phi_x(\theta)\, v \big\rangle, \tag{49}$$

per ogni $u, v \in T_\theta\Theta \cong \mathbb{R}^4$.

Calcolo esplicito del pull-back

Dalla (40) e (48), il pull-back in componenti è:

$$\begin{aligned}(\Phi_x^* \, g_x^{\mathcal{P}})_{ij} &= g_x^{\mathcal{P}}(p_1) \cdot \frac{\partial p_1}{\partial \theta^i} \frac{\partial p_1}{\partial \theta^j} = \frac{1}{p_1 p_2} \cdot (p_1 p_2)^2 \, v_i v_j \\ &= p_1 p_2 \, v_i v_j, \end{aligned} \tag{50}$$

dove $v = (x_1, x_2, -x_1, -x_2)^\top$ e si è usato $\partial p_1 / \partial \theta^i = p_1 p_2 \, v_i$ dalla (48). In forma matriciale:

$$\Phi_x^* \, g_x^{\mathcal{P}} = p_1(\theta, x)\, p_2(\theta, x)\ vv^\top = p_1 p_2 \begin{pmatrix} x_1^2 & x_1 x_2 & -x_1^2 & -x_1 x_2 \\ x_1 x_2 & x_2^2 & -x_1 x_2 & -x_2^2 \\ -x_1^2 & -x_1 x_2 & x_1^2 & x_1 x_2 \\ -x_1 x_2 & -x_2^2 & x_1 x_2 & x_2^2 \end{pmatrix}. \tag{51}$$

Questo è **identico** alla Fisher empirica calcolata nell'esempio motivante (eq. (34)).

La Fisher e' il pull-back della metrica di $\mathcal{P}_x$

La matrice di informazione di Fisher $g_{ij}(\theta)|_x$ è il pull-back della metrica di $\mathcal{P}_x$ tramite Φ_x:

$$\boxed{g_{ij}(\theta)\big|_x = (\Phi_x^* \, g_x^{\mathcal{P}})_{ij}.} \tag{52}$$

La Fisher non è definita direttamente su Θ — è **indotta** da $\mathcal{P}_x$ attraverso Φ_x. La geometria di $\mathcal{M}$ viene da $\mathcal{P}_x$, trasportata su Θ dalla mappa parametrica.

11 La varietà $\mathcal{M}$

Definizione 11.1 (Varietà parametrica Riemanniana)**.** La *varietà parametrica* è lo spazio Θ dotato della metrica di Fisher:

$$\mathcal{M} = \big(\Theta,\ g_{ij}(\theta) = \mathbb{E}_x\big[\Phi_x^* \, g_x^{\mathcal{P}}\big]\big)\,. \tag{53}$$

Riepilogo della struttura a due livelli

	(Θ, δ)	$\mathcal{M} = (\Theta, g)$
Struttura	differenziabile	Riemanniana
Metrica	euclidea δ_{ij}	Fisher $g_{ij}(\theta)$
Curvatura	zero ovunque	dipende da p_θ
Distanze	euclidee in $\mathbb{R}^4$	misurate da g_{ij}
Origine	$\mathbb{R}^4$	$\mathcal{P}_x$ via pull-back
Geodetica	linea retta	curva su $\mathcal{M}$

$\mathcal{M}$ e (Θ, δ) sono **diffeomorfi** come varietà differenziabili (identità come mappa liscia), ma **non isometrici** come varietà Riemanniane.

Pull-back singolare

La metrica pull-back (51) ha rango 1 per ogni x fisso è un prodotto esterno scalato. Solo dopo l'aspettativa su $x \sim p_{\text{data}}$ la Fisher diventa potenzialmente non singolare. Se i dati non coprono tutte le direzioni di $\mathbb{R}^2$ (es. campioni collineari), la Fisher rimane singolare per ogni θ: $\mathcal{M}$ è uno spazio stratificato.

CONFIDE

Questa sezione completa l'esempio motivante. Il Blocco 1 formale generalizza questa costruzione a un modello statistico arbitrario.

12 La varietà parametrica $\mathcal{M}$ e la metrica di Fisher

12.1 Struttura di base

Sia $\Theta \subseteq \mathbb{R}^n$ lo spazio dei parametri di un modello statistico $\{p_\theta(y|x) : \theta \in \Theta\}$. Assumiamo che la mappa $\theta \mapsto p_\theta$ sia regolare a sufficienza (differenziabile, con supporto fissato).

Definizione 12.1 (Varietà parametrica)**.** La *varietà parametrica* $\mathcal{M}$ è lo spazio Θ dotato della struttura differenziabile indotta dalla parametrizzazione. Le coordinate locali su $\mathcal{M}$ sono le componenti di $\theta = (\theta^1, \ldots, \theta^n)$.

Assunzione (non dimostrata)

$\mathcal{M}$ è una varietà differenziabile liscia (C^∞). In particolare si assume che la matrice di Fisher (definita sotto) sia non singolare su tutto $\mathcal{M}$. Le reti neurali con simmetrie di permutazione violano questa assunzione: si veda la Sezione 14.5.

13 La varietà statistica e la metrica di Fisher

13.1 Modello statistico parametrico

Sia $\Theta \subseteq \mathbb{R}^n$ lo spazio dei parametri di un modello statistico parametrico

$$\{p_\theta(y|x) : \theta \in \Theta\}.$$

Assumiamo che per ogni θ la funzione $p_\theta(y|x)$ sia una densità di probabilità rispetto a una misura di riferimento fissata e che il supporto della distribuzione non dipenda dal parametro.

Definiamo la mappa parametrica

$$\Phi : \Theta \to \mathcal{P}, \qquad \Phi(\theta) = p_\theta,$$

dove $\mathcal{P}$ denota lo spazio delle densità di probabilità.

13.2 Varietà statistica

La *varietà statistica* associata al modello è l'immagine della mappa parametrica

$$\mathcal{M} = \Phi(\Theta) = \{p_\theta : \theta \in \Theta\}.$$

Lo spazio $\mathcal{P}$ può essere visto come un sottoinsieme dello spazio funzionale L^1, e $\mathcal{M}$ è dotato della topologia indotta da quella di L^1.

13.3 Struttura differenziabile

Supponiamo che la mappa parametrica Φ sia liscia rispetto ai parametri. Il differenziale della mappa è dato da

$$D\Phi(\theta) = \left(\frac{\partial p_\theta}{\partial \theta^1}, \dots, \frac{\partial p_\theta}{\partial \theta^n}\right).$$

Condizione di rango

Per ogni $\theta \in \Theta$ il differenziale $D\Phi(\theta)$ ha rango pieno

$$\operatorname{rank} D\Phi(\theta) = n.$$

Questa condizione garantisce che la mappa parametrica sia localmente un'immersione e che l'immagine $\mathcal{M}$ sia una varietà differenziabile di dimensione n immersa nello spazio delle distribuzioni.

In particolare, le componenti del parametro

$$\theta = (\theta^1, \dots, \theta^n)$$

forniscono un sistema di coordinate locali sulla varietà $\mathcal{M}$.

13.4 Informazione di Fisher

Su questa varietà si può definire la matrice di informazione di Fisher

$$I_{ij}(\theta) = \mathbb{E}_\theta \left[\partial_i \log p_\theta \; \partial_j \log p_\theta\right].$$

Se la matrice $I(\theta)$ è non singolare per ogni θ, essa definisce una metrica riemanniana sulla varietà statistica $\mathcal{M}$.

13.5 Osservazione sui modelli singolari

In molti modelli moderni di apprendimento automatico, come le reti neurali profonde, la mappa parametrica non soddisfa la condizione di rango pieno a causa di simmetrie di parametrizzazione. In

tali casi la matrice di Fisher diventa singolare e la varietà statistica presenta singolarità geometriche. Questi modelli sono noti come *modelli statistici singolari*.

14 La varietà parametrica $\mathcal{M}$ e la metrica di Fisher

14.1 Struttura di base

Sia $\Theta \subseteq \mathbb{R}^n$ lo spazio dei parametri di un modello statistico parametrico:

$$\{p_\theta(y|x) : \theta \in \Theta\}. \tag{54}$$

Dove y è la variabile osservata, x l'input e θ un sottoinsieme dello spazio dei parametri Assumiamo che la mappa

$$\theta \mapsto p_\theta \,, \tag{55}$$

sia sufficientemente regolare: differenziabile rispetto a θ e con supporto indipendente dal parametro. Questa ultima richiesta equivale ad affermare che l'insieme dei valori possibili della variabile osservata y - $p_\theta(y|x) > 0$ non cambia quando cambiano i parametri del modello.

Definizione 14.1 (Varietà statistica parametrica)**.** La *varietà statistica* associata al modello è l'insieme

$$\mathcal{M} = \{p_\theta(y|x) : \theta \in \Theta\}, \tag{56}$$

cioè l'insieme delle distribuzioni di probabilità realizzabili dal modello.

Quando la parametrizzazione è localmente identificabile, la mappa $\theta \mapsto p_\theta$ induce una struttura differenziabile su $\mathcal{M}$ e la varietà può essere identificata localmente con lo spazio dei parametri Θ.

In particolare, le coordinate locali sulla varietà sono date dalle componenti del vettore dei parametri

$$\theta = (\theta^1, \ldots, \theta^n).$$

Nel caso delle reti neurali, θ rappresenta l'insieme di tutti i parametri della rete (pesi e bias) e $p_\theta(y|x)$ è la distribuzione condizionata sugli output definita dal modello neurale.

Regolarità

Assumiamo che la varietà parametrica $\mathcal{M}$ sia una varietà differenziabile liscia (C^∞) e che la matrice di informazione di Fisher sia non singolare in ogni punto della varietà.

Questa ipotesi garantisce che la matrice di Fisher definisca una metrica riemanniana su $\mathcal{M}$.

Tuttavia, molti modelli di apprendimento moderno, in particolare le reti neurali profonde, violano questa ipotesi. A causa di simmetrie di parametrizzazione (ad esempio permutazioni di neuroni all'interno di uno stesso layer), possono esistere parametri distinti $\theta_1 \neq \theta_2$ che inducono la stessa distribuzione $p_{\theta_1} = p_{\theta_2}$. In tali casi la matrice di Fisher diventa singolare e la varietà statistica presenta singolarità geometriche.

Questi modelli sono noti come *modelli statistici singolari* e sono studiati nella teoria dello *singular learning* [**?**].

14.2 La metrica di Fisher

Definizione 14.2 (Metrica di Fisher)**.** La *matrice di informazione di Fisher* è il campo tensoriale

$$g_{ij}(\theta) \;=\; \mathbb{E}_{p_\theta}[\partial_i \log p_\theta(y|x) \;\cdot\; \partial_j \log p_\theta(y|x)] \,, \tag{57}$$

CONFIDENTIAL

dove $\partial_i = \partial/\partial\theta^i$. Il campo $g = (g_{ij})$ definisce una metrica Riemanniana su $\mathcal{M}$ (Amari, 2016).

Risultato derivato

La mappa $\theta \mapsto g_{ij}(\theta)$ è ben definita come campo su $\mathcal{M}$: dipende da θ attraverso la distribuzione $p_\theta(y|x)$, ma *vive* su $\mathcal{M}$ — non la ridefinisce. La dipendenza $\theta \to p_\theta \to g_{ij}(\theta)$ non è circolare: p_θ è un oggetto derivato da θ che genera g come campo tensoriale.

Analogia strutturale (GR): in relatività generale lo spazio-tempo è $\mathcal{M}$, il tensore metrico $g_{\mu\nu}$ è un campo su $\mathcal{M}$. La materia genera $g_{\mu\nu}$ attraverso le equazioni di Einstein, ma non genera $\mathcal{M}$. Qui: il modello statistico genera g_{ij} attraverso la Fisher identity, ma non genera $\mathcal{M}$.

14.3 La Fisher identity e il legame con la loss

Sia $L(\theta)$ la *negative log-likelihood* (NLL):

$$L(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log p_\theta(y_i|x_i). \tag{58}$$

Fisher identity (esatta per NLL)

Sotto la distribuzione del modello p_θ, vale

$$g_{ij}(\theta) \;=\; \mathbb{E}_{p_\theta}[-\partial_i\partial_j \log p_\theta(y|x)] \;=\; \mathbb{E}_{p_\theta}[H_{ij}(\theta)]\,, \tag{59}$$

dove $H_{ij}(\theta) = \partial_i\partial_j L(\theta)$ è l'Hessiano della loss. Questa è un'identità esatta per NLL, verificabile per calcolo diretto.

△ Attenzione

L'equazione (59) è un'**approssimazione** nel caso pratico:

- L'aspettativa è rispetto a p_θ (distribuzione del modello), non rispetto alla distribuzione reale dei dati.
- Per dataset finiti, $\hat{g}_{ij}(\theta) \approx H_{ij}(\theta)$ con un errore di ordine $O(1/n)$.
- Per MSE (regressione): l'identità vale a meno di un fattore di scala $1/2\sigma^2$ e di una costante additiva che non dipende da θ.

Nella costruzione che segue usiamo $g_{ij} \approx H_{ij}$ come *punto di partenza operativo*, non come fatto esatto.

14.4 Geometria di $\mathcal{M}$: oggetti derivati

Dalla metrica $g_{ij}(\theta)$ si derivano i simboli di Christoffel

$$\Gamma^k_{ij}(\theta) = \frac{1}{2}\, g^{kl}(\theta)\,(\partial_i g_{jl} + \partial_j g_{il} - \partial_l g_{ij})\,, \tag{60}$$

il tensore di Ricci

$$R_{ij}(\theta) = \partial_k\Gamma^k_{ij} - \partial_j\Gamma^k_{ik} + \Gamma^l_{ij}\Gamma^k_{kl} - \Gamma^l_{ik}\Gamma^k_{jl}, \tag{61}$$

e lo scalare di Ricci $R(\theta) = g^{ij}(\theta)\, R_{ij}(\theta)$. In tutte le formule si usa la *convenzione di Einstein*: un indice che compare una volta in alto e una volta in basso è sommato ($g^{kl}g_{kl} \equiv \sum_k \sum_l g^{kl}g_{kl}$). Gli indici liberi ($i$, j in R_{ij}) non sono sommati.

Nota

Tutti questi oggetti dipendono da θ — cambiano ad ogni punto lungo la traiettoria di training. L'oggetto $p_\theta(y|x)$ genera questa dipendenza: plasma g_{ij}, che plasma Γ^k_{ij}, che plasma la geodetica. Un sistema accoppiato, non una sequenza unidirezionale.

14.5 Il caso singolare

△ Attenzione — Fisher singolare

Le reti neurali con simmetrie di permutazione (scambio di neuroni nello stesso layer) hanno $\det g_{ij}(\theta) = 0$ lungo strati di $\mathcal{M}$. In questo caso:

- $\mathcal{M}$ non è una varietà Riemanniana liscia ma uno *spazio stratificato* con strati singolari.
- Il gradiente naturale $g^{-1}\nabla L$ è mal definito sulle singolarità.
- La teoria di Watanabe (2009) sulla *singular learning theory* fornisce un framework alternativo basato su geometria algebrica.

Nella nota tecnica assumiamo Fisher regolare o regolarizzato ($g_{ij} \leftarrow g_{ij} + \lambda I$ con $\lambda \ll 1$). La congettura sul flusso di Ricci (Blocco 4) richiederebbe una riformulazione su questo spazio più ricco.

14.6 Sintesi del Blocco 1

Struttura stabilita — Blocco 1

- $\mathcal{M}$ è una varietà differenziabile con coordinate θ.
- $g_{ij}(\theta)$ è un campo Riemanniano su $\mathcal{M}$, generato da p_θ ma non identico ad esso.
- La Fisher identity $g_{ij} \approx H_{ij}$ connette la geometria di $\mathcal{M}$ alla curvatura della loss landscape.
- Tutti gli oggetti geometrici (Γ, R_{ij}, R) dipendono da θ — la geometria di $\mathcal{M}$ è *dinamica* lungo il training.

Nota

Domanda aperta per il Blocco 2: la loss $L(\theta)$ compare come Hamiltoniana $H(\theta) = n \cdot L(\theta)$ e anche, attraverso la Fisher identity, come sorgente della metrica g_{ij}. Nella costruzione Lagrangiana (Blocco 2), T e V sono definiti separatamente — ma entrambi dipendono da L attraverso canali diversi. Questa dipendenza implicita sarà discussa esplicitamente.

---

15 Dalla surprisal energy alla struttura Hamiltoniana

15.1 L'oggetto generatore: $E_i = -\log p_i$

Sia $p_i(\theta) = p_\theta(y_i|x_i)$ la probabilità che il modello assegna all'output y_i dato l'input x_i.

Definizione 15.1 (Surprisal energy del neurone i)**.**

$$E_i(\theta) = -\log p_i(\theta). \tag{62}$$

E_i è la *surprisal* (o self-information) dell'evento y_i sotto il modello p_θ. Alta sorpresa = bassa probabilità assegnata = alto contributo alla loss.

Nota

E_i è l'unico oggetto primitivo della costruzione. Loss, gradiente e metrica di Fisher emergono tutti dal suo sviluppo di Taylor — non sono postulati separatamente.

15.2 Sviluppo di Taylor di E_i e i tre oggetti

Espandiamo E_i attorno al punto di operazione p_i^0 (valore corrente di p_i prima di una perturbazione $\delta\theta$).

Taylor di E_i — tre ordini, tre oggetti

$$E_i(\theta + \delta\theta) \approx \underbrace{-\log p_i^0}_{\text{0 ordine}} + \underbrace{\frac{\delta p_i}{p_i^0}}_{\text{1 ordine}} + \underbrace{\frac{(\delta p_i)^2}{2(p_i^0)^2}}_{\text{2 ordine}} + O(\delta^3). \tag{63}$$

Sommando su tutti gli N neuroni e passando alle derivate rispetto a θ:

$$\text{0 ordine:} \quad \tfrac{1}{N}\textstyle\sum_i E_i(\theta) = L(\theta) \quad \text{(la loss — NLL)}, \tag{64}$$

$$\text{1 ordine:} \quad \nabla_\theta L(\theta) \quad \text{(gradiente della loss — forza su } \mathcal{M}\text{)}, \tag{65}$$

$$\text{2 ordine:} \quad g_{ij}(\theta) = \mathbb{E}\big[\partial_i \log p_\theta \cdot \partial_j \log p_\theta\big] \quad \text{(metrica di Fisher — inerzia di } \mathcal{M}\text{)}. \tag{66}$$

Nota

I tre oggetti non sono indipendenti: provengono dallo stesso E_i. Questo ha una conseguenza importante nella costruzione Hamiltoniana (Sezione 15.7).

15.3 La Hamiltoniana in rappresentazione di posizione

Risultato derivato

Sommando le surprisal energies su tutti gli N neuroni:

$$H(\theta) = \sum_{i=1}^{N} E_i(\theta) = N \cdot L(\theta). \tag{67}$$

$H(\theta)$ dipende solo da θ, non dai momenti. Minimizzare L equivale a trovare il ground state di un sistema la cui energia è la surpresa informativa del modello.

△ Attenzione

$H(\theta) = N \cdot L(\theta)$ è la Hamiltoniana **incompleta**: mancano i momenti coniugati. Senza momenti non si scrive la dinamica Hamiltoniana completa, né la Lagrangiana, né l'azione. I momenti emergono dalla metrica di Fisher — passo successivo.

15.4 Momenti coniugati dalla metrica di Fisher

Il termine cinetico naturale su una varietà Riemanniana $(\mathcal{M}, g)$ è $T = \frac{1}{2} g_{ij}(\theta)\, \dot{\theta}^i \dot{\theta}^j$. Il momento coniugato a θ^i è:

$$\pi_i = \frac{\partial T}{\partial \dot{\theta}^i} = g_{ij}(\theta)\, \dot{\theta}^j. \tag{68}$$

g_{ij} come tensore di inerzia

La metrica di Fisher $g_{ij}(\theta)$ è il tensore di inerzia dello spazio parametrico.

- In spazio piatto ($g_{ij} = \delta_{ij}$): $\pi_i = \dot{\theta}^i$ — momento ordinario.
- Su $\mathcal{M}$ curva: le direzioni ad alta curvatura Fisher portano piu' momento a parita' di velocita'.

Il gradiente naturale di Amari corregge esattamente questo: $\dot{\theta}^i = -g^{ij}(\theta)\, \partial_j L$ pesa le direzioni con l'inerzia locale di $\mathcal{M}$.

15.5 La Hamiltoniana completa via trasformata di Legendre

Invertendo $\pi_i = g_{ij}\dot{\theta}^j$ si ottiene $\dot{\theta}^i = g^{ij}(\theta)\, \pi_j$.

Hamiltoniana completa in spazio delle fasi

$$H(\theta, \pi) = \frac{1}{2}\, g^{ij}(\theta)\, \pi_i \pi_j + N\, L(\theta) = T(\theta, \pi) + V(\theta). \tag{69}$$

In spazio delle fasi (θ, π): T dipende da π dato θ, V dipende solo da θ — **indipendenti per costruzione**.

15.6 La Lagrangiana e l'azione

$$\mathcal{L}(\theta, \dot{\theta}) = T - V = \frac{1}{2}\, g_{ij}(\theta)\, \dot{\theta}^i \dot{\theta}^j - N\, L(\theta). \tag{70}$$

$$S[\theta] = \int_a^b \mathcal{L}(\theta, \dot{\theta})\, dt. \tag{71}$$

Equazioni di Eulero–Lagrange su $\mathcal{M}$

$\delta S = 0$ produce:

$$\ddot{\theta}^k + \Gamma^k_{ij}(\theta)\, \dot{\theta}^i \dot{\theta}^j = -g^{kj}(\theta)\, N\, \partial_j L(\theta). \tag{72}$$

Lato sinistro: derivata covariante di $\dot{\theta}$ (accelerazione su $\mathcal{M}$). Lato destro: forza esterna dalla loss. Per $L = 0$: si recupera l'equazione geodetica libera.

15.7 La tensione strutturale: L genera sia V che g

△ Tensione strutturale

La loss $L(\theta)$ compare in due ruoli nella costruzione:

1. **Potenziale**: $V(\theta) = N\, L(\theta)$.
2. **Sorgente della metrica**: $g_{ij}(\theta) \approx H_{ij}(\theta) = \partial_i \partial_j L(\theta)$ via Fisher identity.

Quindi $T = \frac{1}{2} g_{ij}\dot{\theta}^i \dot{\theta}^j$ dipende implicitamente da L attraverso g_{ij}. In spazio delle fasi T e V sono formalmente indipendenti, ma entrambi sono funzionali di L attraverso canali diversi.

CONFIDE

Non e‘ una contraddizione: e‘ una struttura accoppiata che riflette il fatto che tutto emerge da $E_i = -\log p_i$. Un trattamento rigoroso deve dichiarare esplicitamente che g_{ij} e L non sono oggetti indipendenti.

15.8 Sintesi del Blocco 2

Struttura stabilita — Blocco 2

- $E_i = -\log p_i$: unico oggetto primitivo. Loss, gradiente e Fisher = tre ordini di Taylor di E_i.
- $g_{ij}(\theta)$: tensore di inerzia di $\mathcal{M}$; momenti $\pi_i = g_{ij}\dot{\theta}^j$ emergono naturalmente.
- $H(\theta, \pi) = T + V$: ben definita in spazio delle fasi.
- $\mathcal{L} = T - V$: derivata, non postulata.
- $\delta S = 0$: traiettoria classica di training come E–L su $\mathcal{M}$.

Nota

Tensione aperta verso il Blocco 3: $\delta S = 0$ determina $\theta(t)$ dato $g_{ij}(\theta)$. Ma $g_{ij}(\theta(t))$ evolve mentre θ si muove. Il sistema e‘ accoppiato: la traiettoria deforma la geometria, la geometria deforma la traiettoria. S descrive la dinamica di θ dato g — non dice come g evolve. Questa e‘ la domanda del Blocco 3.

---

16 Blocco 2-bis: dall’energia del neurone all’azione (senza Hamiltoniana)

Nota

Questo blocco è una formulazione alternativa del Blocco 2. La struttura Hamiltoniana (momenti coniugati, trasformata di Legendre, spazio delle fasi) viene **bypassata completamente**. La Lagrangiana e l’azione emergono direttamente da $E_i = -\log p_i$ in due passi: Taylor e assemblaggio. I due approcci sono equivalenti on-shell (lungo le traiettorie fisiche $\delta S = 0$), ma questo è più diretto e ha meno assunzioni intermedie.

16.1 L’oggetto primitivo e il suo Taylor

Sia $p_i(\theta) = p_\theta(y_i|x_i)$ la probabilità del modello sull’i-esimo campione. L’unico oggetto primitivo è:

$$E_i(\theta) = -\log p_i(\theta). \tag{73}$$

Taylor di E_i — due oggetti, non tre

Lo sviluppo di Taylor di E_i attorno al punto corrente p_i^0 produce **due oggetti geometricamente distinti**:

$$0^\circ \text{ ordine:} \quad V(\theta) = \frac{1}{N}\sum_{i=1}^{N} E_i(\theta) = L(\theta) \quad \text{— il potenziale (loss / NLL),} \tag{74}$$

$$2^\circ \text{ ordine:} \quad g_{ij}(\theta) = \mathbb{E}\big[\partial_i \log p_\theta \cdot \partial_j \log p_\theta\big] \quad \text{— la metrica (Fisher).} \tag{75}$$

Il termine di primo ordine ∇L non entra nella Lagrangiana — è la forza, non la struttura.

Nota

Nel Blocco 2 i tre ordini generavano tre oggetti separati che venivano poi ricombinati via Hamiltoniana. Qui si usano solo il 0° e il 2° ordine, direttamente come V e T nella Lagrangiana. La Hamiltoniana non serve come intermediario.

16.2 Assemblaggio diretto della Lagrangiana

Dal potenziale (74) e dalla metrica (75) si scrive immediatamente il termine cinetico naturale su $\mathcal{M}$:

$$T(\theta, \dot\theta) = \frac{1}{2}\, g_{ij}(\theta)\, \dot\theta^i \dot\theta^j, \tag{76}$$

e la Lagrangiana:

Lagrangiana — derivata direttamente da E_i

$$\mathcal{L}(\theta, \dot\theta) = T(\theta, \dot\theta) - N \cdot V(\theta) = \frac{1}{2}\, g_{ij}(\theta)\, \dot\theta^i \dot\theta^j - N\, L(\theta). \tag{77}$$

T viene dal 2° ordine di Taylor di E_i (la metrica Fisher).
V viene dal 0° ordine di Taylor di E_i (la loss).
Entrambi emergono dallo stesso oggetto E_i — nessun intermediario Hamiltoniano richiesto.

16.3 La tensione T/V si dissolve

Nel Blocco 2 si era segnalata una tensione: $L(\theta)$ appariva sia come potenziale V che come sorgente della metrica $g_{ij} \approx H_{ij} = \partial_i \partial_j L$, rendendo T e V implicitamente dipendenti.

Risoluzione della tensione

In questa formulazione la tensione non esiste: T e V provengono **da ordini diversi dello stesso Taylor**. Non sono due oggetti costruiti separatamente che poi si sovrappongono — sono due aspetti dello stesso E_i a scale diverse.

Ordine di Taylor	Oggetto	Ruolo in $\mathcal{L}$
0°	$L(\theta)$	Potenziale V
1°	$\nabla L(\theta)$	Forza (non in $\mathcal{L}$)
2°	$g_{ij}(\theta)$	Termine cinetico T

La dipendenza implicita $g_{ij} \approx \partial_i \partial_j L$ non è una tensione — è la **struttura** del problema: la geometria di $\mathcal{M}$ è codificata nella curvatura della loss.

16.4 L'azione e il principio variazionale

$$S[\theta] = \int_a^b \mathcal{L}(\theta, \dot{\theta})\, dt = \int_a^b \left[\frac{1}{2}\, g_{ij}(\theta)\, \dot{\theta}^i \dot{\theta}^j - N\, L(\theta) \right] dt. \tag{78}$$

Equazioni del moto da $\delta S = 0$

Il principio variazionale $\delta S = 0$ dà le equazioni di Eulero–Lagrange su $\mathcal{M}$:

$$\ddot{\theta}^k + \Gamma^k_{ij}(\theta)\, \dot{\theta}^i \dot{\theta}^j = -g^{kj}(\theta)\, N\, \partial_j L(\theta). \tag{79}$$

Lato sinistro: accelerazione covariante su $\mathcal{M}$ — geometria pura.
Lato destro: forza dalla loss — dinamica.
Per $L = 0$: geodetica libera $\ddot{\theta}^k + \Gamma^k_{ij}\dot{\theta}^i\dot{\theta}^j = 0$.

△ Attenzione

L'equazione (79) è identica a quella del Blocco 2 (eq. 72). I due approcci sono **equivalenti on-shell**. La differenza è nella struttura concettuale: qui non è mai apparso uno spazio delle fasi, né un momento coniugato, né una trasformata di Legendre.

16.5 Cosa si perde bypassando la Hamiltoniana

Nota

La formulazione Hamiltoniana del Blocco 2 non è ridondante — ha vantaggi specifici che questa formulazione non offre:

- I momenti $\pi_i = g_{ij}\dot{\theta}^j$ hanno un'interpretazione geometrica diretta (abbassamento di indice, isomorfismo $\flat$).
- La struttura simplettica di $T^*\mathcal{M}$ è naturale per integratori geometrici (es. Kelshaw & Magri, 2023).
- Il path integral euclideo si scrive naturalmente in spazio delle fasi — la correzione di DeWitt (Appendice A) parte da lì.

Per la congettura sul flusso di Ricci (Blocco 3) la formulazione Lagrangiana è sufficiente. Per eventuali sviluppi quantistici o stocastici, la formulazione Hamiltoniana resta necessaria.

16.6 Sintesi del Blocco 2-bis

Struttura stabilita — Blocco 2-bis

- $E_i = -\log p_i$: oggetto primitivo unico.
- 0° Taylor $\to L(\theta) =$ potenziale V.
- 2° Taylor $\to g_{ij}(\theta) =$ metrica, termine cinetico T.
- $\mathcal{L} = T - V$: assemblata direttamente, senza Hamiltoniana né momenti.
- $\delta S = 0$: equazioni di moto su $\mathcal{M}$ curva, identiche al Blocco 2 on-shell.
- La tensione T/V del Blocco 2 si dissolve: sono due ordini dello stesso Taylor.

Nota

Verso il Blocco 3: $\delta S = 0$ chiude la dinamica di $\theta(t)$ dato g_{ij}. La domanda aperta resta la stessa: come evolve $g_{ij}(\theta(t))$ durante il training? La risposta è la congettura sul flusso di Ricci.

Fine Blocco 2-bis. Formulazione alternativa al Blocco 2 — equivalente on-shell, più diretta, senza struttura Hamiltoniana.

---

17 La varietà dinamica e la congettura sul flusso di Ricci

Nota

Questo blocco ha tre parti con statuto epistemico distinto: (1) la famiglia $(\mathcal{M}, g(\theta(t)))$ è una **definizione**; (2) la congettura sul flusso di Ricci è una **congettura aperta**; (3) l'esistenza di g^*_{ij} è una **domanda aperta**, conseguenza della congettura se vera.

17.1 Setting: la famiglia $(\mathcal{M}, g(\theta(t)))$

Dopo il Blocco 2 il sistema è accoppiato. Da un lato, le equazioni di Eulero–Lagrange descrivono il moto di $\theta(t)$ dato il campo metrico:

$$\ddot{\theta}^k + \Gamma^k_{ij}(\theta)\,\dot{\theta}^i\dot{\theta}^j = -g^{kj}(\theta)\,N\,\partial_j L(\theta). \tag{80}$$

Dall'altro, $g_{ij}(\theta(t))$ evolve mentre θ si muove, perché g_{ij} dipende da θ attraverso p_θ. Il sistema non è chiuso: (80) dà $\theta(t)$ dato g, ma non dice come g evolve.

CONFIDENTIAL

Setting formale: famiglia di varietà Riemanniane

L'oggetto geometrico corretto non è una singola varietà Riemanniana $(\mathcal{M}, g)$, ma una **famiglia parametrizzata**:

$$\big\{(\mathcal{M},\, g(\theta(t)))\big\}_{t\in[0,T_{\text{train}}]}, \tag{81}$$

dove:

- $\mathcal{M}$ è fissa come varietà differenziabile (la topologia non cambia durante il training);
- $g(\theta(t))$ è il campo metrico di Fisher, che varia punto per punto lungo la traiettoria;
- il tempo di training t parametrizza la deformazione della geometria di $\mathcal{M}$.

Questo è il setting naturale per il flusso di Ricci (Hamilton, 1982): una famiglia $(M, g(t))$ dove la metrica evolve secondo una legge differenziale.

△ Attenzione

Il flusso di Ricci standard (Hamilton, 1982) fa evolvere g **autonomamente** nello spazio delle metriche — senza traiettoria, senza dati. Qui g evolve **lungo** $\theta(t)$, guidata dai dati attraverso p_θ. Sono due oggetti distinti: il secondo è più debole, ma è quello fisicamente rilevante per il training.

17.2 La congettura

Il sistema accoppiato $(\theta(t),\, g(\theta(t)))$ è aperto: manca la legge di evoluzione di g. La congettura propone che questa legge sia il flusso di Ricci.

Congettura — flusso di Ricci lungo la traiettoria

Esiste una riparametrizzazione $\tau(\theta(t))$ del tempo di training tale che la metrica di Fisher evolve come:

$$\frac{\partial g_{ij}(\theta)}{\partial \tau} = -2\, R_{ij}(\theta) \quad \text{lungo } \theta(t). \tag{82}$$

Se vera, (82) **chiude il sistema accoppiato**:

$$\begin{cases} \ddot{\theta}^k + \Gamma^k_{ij}\dot{\theta}^i\dot{\theta}^j = -g^{kj} N \partial_j L(\theta) & \text{(moto di } \theta\text{, dal Blocco 2)} \\ \partial_\tau g_{ij} = -2R_{ij}(\theta) & \text{(evoluzione di } g\text{, congettura)} \end{cases} \tag{83}$$

Nota

L'interpretazione fisica di (82) è diretta. Il flusso di Ricci contrae le regioni con $R_{ij} > 0$ (parametri mal condizionati, loss landscape ripida) ed espande le regioni con $R_{ij} < 0$ (parametri ben condizionati, loss landscape piatta). La congettura afferma che il training SGD non minimizza solo L — redistribuisce attivamente il condizionamento su $\mathcal{M}$. Convergenza = curvatura uniforme = Hessiano uniformemente condizionato su tutta la traiettoria.

Assunzioni necessarie per (82)

La derivazione della congettura (si veda l'Appendice A) richiede:

1. **Rumore SGD gaussiano**: il rumore di mini-batch è approssimato da rumore bianco gaussiano con scala $\xi \propto \eta \cdot \mathrm{Var}(\nabla L)$. Il rumore reale dipende dalla composizione del batch e non è gaussiano in generale.
2. **Fisher non singolare**: $\det g_{ij}(\theta) > 0$ su tutta $\mathcal{M}$. Violata per reti con simmetrie di permutazione (si veda Sezione 1.5).
3. **Esistenza di τ**: la riparametrizzazione $\tau(\theta(t))$ esiste ed è regolare. Questa è parte di ciò che resta da dimostrare.

17.3 La domanda aperta: esiste g^*_{ij}?

La congettura (82), se vera, apre una domanda più profonda sulla struttura geometrica del training.

Nel Blocco 2 si sono distinte due curve su $\mathcal{M}$:

$$\text{Traiettoria forzata:} \quad \dot{\theta}^i = -g^{ij}(\theta)\, \partial_j L(\theta) \quad \text{(spinta dalla loss)} \tag{84}$$

$$\text{Geodetica libera:} \quad \ddot{\theta}^k + \Gamma^k_{ij}(\theta)\, \dot{\theta}^i\dot{\theta}^j = 0 \quad \text{(solo geometria)} \tag{85}$$

Sono due oggetti distinti: la prima è guidata da L, la seconda è libera.

Domanda aperta — loss come geometria

Esiste una metrica $g^*_{ij}(\theta)$ tale che la traiettoria forzata (84) coincide con la geodetica libera (85) su $(\mathcal{M}, g^*)$?

$$\exists\, g^*_{ij}(\theta) \;:\quad \dot{\theta}^i = -g^{ij}\partial_j L \iff \ddot{\theta}^k + \Gamma^{*k}_{ij}\dot{\theta}^i\dot{\theta}^j = 0. \tag{86}$$

Se sì: $L(\theta)$ non è una forza esterna su $\mathcal{M}$ — è codificata nella geometria di $\mathcal{M}$ attraverso g^*_{ij}. Il training è una **geodetica libera**.

Analogia con la relatività generale: la gravità non è una forza — è curvatura dello spazio-tempo. Qui: la loss non è una forza — è curvatura dello spazio dei parametri.

Nota

Tre oggetti restano da costruire esplicitamente:

1. **Esistenza** di g^*_{ij} — non è garantita in generale.
2. **Regolarità** di g^*_{ij} su $\mathcal{M}$ — condizioni sufficienti da identificare.
3. **Relazione tra g^*_{ij} e il flusso di Ricci**: g^*_{ij} potrebbe essere il punto fisso del flusso (82) — cioè la metrica di curvatura uniforme a cui il training converge.

Questi sono i tre passi aperti del programma di ricerca.

17.4 Sintesi del Blocco 3

Struttura stabilita — Blocco 3

- Il setting corretto è la famiglia $(\mathcal{M}, g(\theta(t)))$: topologia fissa, geometria dinamica.
- Il sistema accoppiato (83) è chiuso dalla congettura sul flusso di Ricci — se vera.
- La domanda su g^*_{ij} è la conseguenza più profonda: se esiste, la loss è geometria, non forza.

CONFIDEN

Fine Blocco 3. La derivazione dettagliata della congettura (SGD → Fokker–Planck → DeWitt → Perelman → Ricci flow) è in Appendice A.

A Derivazione della congettura: da SGD al flusso di Ricci

Nota

Questa appendice è a uso personale. Contiene la catena di derivazione completa in quattro passi. Ogni passo ha assunzioni forti — indicate esplicitamente. Non è destinata ai colleghi nella versione attuale.

Passo 1 — SGD come diffusione su $\mathcal{M}$

Nel limite di learning rate piccolo, SGD con rumore gaussiano converge all'equazione di Fokker–Planck su $\mathcal{M}$:

$$\frac{\partial \rho}{\partial \tau} = \Delta_g \rho, \tag{87}$$

dove Δ_g è l'operatore di Laplace–Beltrami con metrica $g_{ij}(\theta)$ e $\rho(\theta, \tau)$ è la distribuzione dei parametri sotto SGD.

Assunzione (non dimostrata)

Rumore SGD gaussiano, learning rate $\eta \to 0$, batch variance finita. Riferimenti: Li et al. (2017), Mandt et al. (2017).

Passo 2 — Path integral e correzione di DeWitt

La traiettoria di training si scrive come path integral euclideo su $\mathcal{M}$. Per rendere la misura covariante (indipendente dalla scelta di coordinate) si introduce la correzione di DeWitt:

$$L_{\text{eff}} = L(\theta) + \frac{\xi^2}{12} R(\theta), \tag{88}$$

dove ξ è la scala del rumore SGD e $R(\theta)$ è lo scalare di Ricci. Il termine $\frac{\xi^2}{12}R$ agisce come forza che allontana la traiettoria dalle regioni ad alta curvatura. Per $\xi \to 0$ (training deterministico) si recupera la discesa del gradiente standard.

Assunzione (non dimostrata)

Misura del path integral covariante. Riferimenti: DeWitt (1957), Kleinert (2009, Cap. 10).

Passo 3 — Funzionale di Perelman come energia libera

Posto $f = -\log \rho$ (entropia negativa della distribuzione dei parametri), il funzionale di Perelman è:

$$\mathcal{F}(g, f) = \int_{\mathcal{M}} \big(R(\theta) + |\nabla f(\theta)|^2\big) e^{-f} \, d\text{vol}_g. \tag{89}$$

$\mathcal{F}$ misura la combinazione di curvatura totale (geometria) e informazione di Fisher della distribuzione dei parametri (statistica) — l'energia libera geometrica del processo di training.

Teorema di Perelman (2003)

Il flusso gradiente di $\mathcal{F}$ rispetto a g è il flusso di Ricci:

$$\frac{\partial g_{ij}}{\partial t} = -2\, R_{ij}. \tag{90}$$

Passo 4 — Chiusura della catena

Catena completa

Passo	Da	A
1	SGD con rumore gaussiano	$\partial_\tau \rho = \Delta_g \rho$ su $\mathcal{M}$
2	Path integral covariante	Termine DeWitt $\frac{\xi^2}{12} R(\theta)$
3	$f = -\log \rho$	Funzionale di Perelman $\mathcal{F}(g, f)$
4	Minimizza $\mathcal{F}$ rispetto a g	Flusso di Ricci $\partial_\tau g_{ij} = -2R_{ij}$

Conclusione: SGD con rumore gaussiano su $\mathcal{M}$ implica che la metrica di Fisher evolve compatibilmente con un flusso di Ricci. Sotto le assunzioni dei Passi 1–3, questo è un risultato derivabile, non solo una congettura.

△ Fragilità della catena

- **Passo 1**: il rumore SGD reale non è gaussiano. Approssimazione valida solo per batch grandi (teorema centrale del limite).
- **Passo 2**: la correzione DeWitt richiede una scelta specifica della misura del path integral. Altre scelte danno termini di curvatura diversi.
- **Passo 3**: il funzionale di Perelman è definito per varietà compatte senza bordo. $\mathcal{M}$

parametrica non è compatta in generale.

- **Passo 4**: il flusso gradiente di $\mathcal{F}$ è il flusso di Ricci nello spazio delle metriche — non lungo $\theta(t)$. Il passaggio al flusso lungo la traiettoria richiede la riparametrizzazione $\tau(\theta(t))$, la cui esistenza è parte di ciò che resta da dimostrare.

Fine Appendice. Riferimenti chiave: Li et al. (2017); Mandt et al. (2017); DeWitt (1957); Kleinert (2009); Perelman (2003); Hamilton (1982); Amari (2016).

CONFIDENTIAL